

Análise Exploratória e PCA para Avaliação da Separabilidade de Classes no Wine Quality Dataset

João Victor de Abreu, João Victor Falcão, Lucas Martins e Lucas Teixeira

Departamento de Engenharia de Teleinformática (DETI)

Universidade Federal do Ceará (UFC)

Fortaleza, Ceará, Brasil

Resumo—Este trabalho apresenta uma análise exploratória do conjunto de dados *Wine Quality*, considerando conjuntamente 6497 amostras de vinhos tintos e brancos e 11 preditores físico-químicos. Foram conduzidas análises monovariadas incondicionais e condicionadas à classe de qualidade, análise bivariada por meio do coeficiente de correlação de Pearson e uma implementação de Análise de Componentes Principais (PCA) baseada em operações matriciais.

As classes observadas de *quality* variam de 3 a 9 e apresentam forte desbalanceamento. Na base combinada, destacam-se as correlações entre *free sulfur dioxide* e *total sulfur dioxide* ($\rho = 0,721$) e entre *density* e *alcohol* ($\rho = -0,687$). As duas primeiras componentes principais preservam aproximadamente 50,22% da variância total. Apesar de tendências em alguns atributos e deslocamentos entre centroides de classes, permanece elevada sobreposição nas representações uni e bidimensionais, indicando que a separabilidade das classes de qualidade não é simples.

Index Terms—*Wine Quality*, análise exploratória de dados, correlação de Pearson, PCA, redução de dimensionalidade.

I. INTRODUÇÃO

A avaliação sensorial da qualidade de vinhos depende de especialistas humanos e envolve fatores subjetivos. Em paralelo, propriedades físico-químicas como acidez, densidade, concentração de dióxido de enxofre, açúcar residual e teor alcoólico podem ser obtidas por medições objetivas.

O conjunto *Wine Quality*, introduzido por Cortez *et al.* [1], reúne medições de amostras portuguesas de *Vinho Verde* tinto e branco e permite investigar a relação entre atributos físico-químicos e qualidade sensorial.

Antes da construção de modelos preditivos, a análise exploratória é importante para caracterizar distribuições, identificar assimetrias e valores extremos, estudar dependências lineares e avaliar a separabilidade entre classes. Adicionalmente, a Análise de Componentes Principais (PCA) fornece uma representação de menor dimensionalidade por meio de direções ortogonais de máxima variância [2].

Neste trabalho, os subconjuntos de vinho tinto e branco são concatenados e analisados como uma única base com 11 preditores. O tipo de vinho é preservado apenas como metadado auxiliar e não participa dos cálculos principais. O objetivo é caracterizar estatisticamente os atributos, identificar suas principais dependências e avaliar a separabilidade das classes de qualidade em representações monovariadas, bivariadas e multivariadas.

II. MÉTODOS

A. Descrição do conjunto de dados

Foram utilizados os subconjuntos de vinho tinto, com $N_{\text{tinto}} = 1599$, e vinho branco, com $N_{\text{branco}} = 4898$. Como ambos possuem a mesma estrutura de atributos, as bases foram concatenadas por linhas, resultando em

$$N = 1599 + 4898 = 6497 \quad (1)$$

observações.

Cada amostra possui $D = 11$ preditores físico-químicos contínuos: *fixed acidity*, *volatile acidity*, *citric acid*, *residual sugar*, *chlorides*, *free sulfur dioxide*, *total sulfur dioxide*, *density*, *pH*, *sulphates* e *alcohol*. A variável *quality* é utilizada como rótulo de classe. Na base combinada são observadas $L = 7$ classes, $\mathcal{L} = \{3, 4, 5, 6, 7, 8, 9\}$.

A Tabela I apresenta a distribuição das observações entre as classes de qualidade.

Tabela I
DISTRIBUIÇÃO DAS CLASSES DE QUALIDADE.

Classe	N_l	Percentual
3	30	0,46%
4	216	3,32%
5	2138	32,91%
6	2836	43,65%
7	1079	16,61%
8	193	2,97%
9	5	0,08%

As classes 5 e 6 concentram aproximadamente 76,56% das observações, enquanto a classe 9 contém apenas cinco amostras. Por isso, estatísticas das classes menos representadas, especialmente da classe 9, devem ser interpretadas com cautela.

B. Análise monovariada

Para cada preditor d , foram calculados a média amostral μ_d , o desvio padrão amostral σ_d e o coeficiente de assimetria γ_d :

$$\mu_d = \frac{1}{N} \sum_{i=1}^N x_{i,d}, \quad (2)$$

$$\sigma_d = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (x_{i,d} - \mu_d)^2}, \quad (3)$$

$$\gamma_d = \frac{\sum_{i=1}^N (x_{i,d} - \mu_d)^3}{(N-1)\sigma_d^3}. \quad (4)$$

A análise foi repetida condicionando cada preditor à classe de qualidade, produzindo $\mu_{d|l}$, $\sigma_{d|l}$ e $\gamma_{d|l}$ para as $D \times L = 77$ combinações preditor-classe.

As estatísticas incondicionais foram calculadas sobre a base combinada. Para auxiliar a interpretação visual das distribuições agregadas, alguns histogramas foram estratificados pelo tipo de vinho.

As tabelas completas de médias, desvios padrão e assimetrias condicionais, bem como os histogramas e box-plots correspondentes às 77 combinações preditor-classe, são disponibilizados no repositório do projeto.

C. Análise bivariada

A dependência linear entre pares de preditores foi quantificada pelo coeficiente de correlação de Pearson:

$$\rho_{d_i, d_j} = \frac{\sum_{k=1}^N (x_{k,i} - \mu_i)(x_{k,j} - \mu_j)}{\sqrt{\sum_{k=1}^N (x_{k,i} - \mu_i)^2 \sum_{k=1}^N (x_{k,j} - \mu_j)^2}}. \quad (5)$$

Com $D = 11$, existem

$$\binom{11}{2} = 55 \quad (6)$$

pares distintos de preditores.

Foram gerados gráficos de dispersão individualmente para os 55 pares, com indicação das classes de qualidade, e todos esses gráficos são mantidos no repositório do projeto.

A matriz principal de correlação foi calculada para a base combinada. Matrizes adicionais foram obtidas separadamente para vinhos tintos e brancos como análise complementar da heterogeneidade entre os subconjuntos.

Foi utilizado um *pairplot* envolvendo os atributos presentes entre as três maiores correlações em módulo da base combinada.

A presença de possíveis valores atípicos também foi investigada pelo critério de $1,5 \times IQR$, considerando como candidatos a *outliers* valores localizados abaixo de $Q_1 - 1,5IQR$ ou acima de $Q_3 + 1,5IQR$.

D. Análise de Componentes Principais

A PCA foi implementada diretamente por operações matriciais, sem o uso de uma rotina pronta de PCA. Inicialmente, cada preditor foi padronizado:

$$z_{i,d} = \frac{x_{i,d} - \mu_d}{\sigma_d}. \quad (7)$$

Se Z representa a matriz dos dados padronizados, a matriz de covariância amostral é

$$\Sigma = \frac{1}{N-1} Z^T Z. \quad (8)$$

Em seguida, foi realizada a decomposição espectral

$$\Sigma \mathbf{v}_j = \lambda_j \mathbf{v}_j, \quad (9)$$

com ordenação decrescente dos autovalores e respectivos autovetores. A projeção nas duas primeiras componentes principais é

$$X_{PCA} = Z [\mathbf{v}_1 \quad \mathbf{v}_2]. \quad (10)$$

A variável *quality* e o tipo de vinho não participam do cálculo das componentes; são utilizados apenas posteriormente para análise e visualização.

III. RESULTADOS E DISCUSSÃO

A. Análise monovariada

A Tabela II resume as estatísticas incondicionais dos onze preditores.

Tabela II
ESTATÍSTICAS MONOVIARIADAS INCONDICIONAIS.

Preditor	μ	σ	γ
Fixed acidity	7,215	1,296	1,723
Volatile acidity	0,340	0,165	1,495
Citric acid	0,319	0,145	0,472
Residual sugar	5,443	4,758	1,435
Chlorides	0,056	0,035	5,398
Free sulfur dioxide	30,525	17,749	1,220
Total sulfur dioxide	115,745	56,522	-0,001
Density	0,995	0,003	0,503
pH	3,219	0,161	0,387
Sulphates	0,531	0,149	1,797
Alcohol	10,492	1,193	0,566

A maior assimetria positiva ocorre em *chlorides*, $\gamma \approx 5,398$, indicando uma cauda pronunciada na direção de valores mais altos. Também apresentam assimetria positiva relevante *sulphates*, *fixed acidity*, *volatile acidity*, *residual sugar* e *free sulfur dioxide*. Em contraste, *total sulfur dioxide* apresenta assimetria praticamente nula.

A Fig. 1 exemplifica esse comportamento para *chlorides*. O histograma evidencia concentração das observações em valores baixos e uma cauda prolongada à direita, enquanto o box-plot mostra diversos valores extremos.

A análise condicionada mostra tendências relacionadas à qualidade em alguns atributos. A Tabela III apresenta dois exemplos de maior interesse para a discussão.

Para *alcohol*, observa-se tendência de aumento das médias nas classes de qualidade mais elevadas, especialmente entre as classes 5 e 8. Em *volatile acidity*, ocorre tendência geral de redução.

A Fig. 2 evidencia, entretanto, que diferenças nas médias não correspondem a uma separação completa das distribuições. Os histogramas e box-plots apresentam forte sobreposição entre classes vizinhas, de modo que nenhum desses preditores fornece separação unidimensional perfeita.




Figura 1. Análise incondicional de *chlorides*: histograma segmentado por tipo de vinho (esquerda) e box-plot global (direita).

Tabela III
MÉDIAS CONDICIONAIS DE ATRIBUTOS SELECIONADOS.

Preditor	q=3	q=4	q=5	q=6	q=7	q=8	q=9
Volatile acidity	0,517	0,458	0,390	0,314	0,289	0,291	0,298
Alcohol	10,215	10,180	9,838	10,588	11,386	11,679	12,180




Figura 2. Distribuição de *alcohol* condicionada às sete classes: histogramas (esquerda) e box-plots (direita).

A classe 9 possui apenas cinco observações; por isso, suas estimativas de desvio padrão e assimetria apresentam elevada incerteza amostral. As tabelas completas de médias, desvios padrão e assimetrias condicionais são mantidas no repositório, evitando ocupar espaço excessivo no artigo.

B. Análise bivariada

A Fig. 3 apresenta a matriz de correlação de Pearson da base combinada.

As maiores correlações em módulo são apresentadas na Tabela IV.

A maior correlação da base combinada ocorre entre *free sulfur dioxide* e *total sulfur dioxide*, $\rho = 0,721$. A associação entre *density* e *alcohol* é negativa, $\rho = -0,687$, enquanto *residual sugar* e *density* apresentam $\rho = 0,553$.

Tabela IV
MAIORES CORRELAÇÕES DE PEARSON EM MÓDULO NA BASE COMBINADA.

Par de preditores	ρ
Free SO ₂ – Total SO ₂	0,721
Density – Alcohol	-0,687
Residual sugar – Density	0,553
Residual sugar – Total SO ₂	0,495
Fixed acidity – Density	0,459

Essas associações sugerem possível redundância linear parcial entre alguns atributos, mas não implicam equivalência entre eles.

Como análise complementar, foram comparadas correlações entre os subconjuntos. Para *density* e *residual sugar*, obtém-se




Figura 3. Matriz de correlação de Pearson para a base combinada.

$\rho = 0,355$ nos vinhos tintos, $\rho = 0,839$ nos vinhos brancos e $\rho = 0,553$ na base combinada. Para *density* e *alcohol*, os valores são $-0,496$, $-0,780$ e $-0,687$, respectivamente. Essas diferenças evidenciam heterogeneidade entre os dois subconjuntos e recomendam cautela na interpretação das relações da população agregada.

A Fig. 4 apresenta os atributos envolvidos nas correlações de maior magnitude. Os pares mais fortemente correlacionados apresentam tendências aproximadamente lineares, embora com dispersão considerável e presença de observações extremas. Para pares com valores reduzidos de $|\rho|$, entretanto, não se pode descartar uma eventual relação não linear apenas com base no coeficiente de Pearson.

Mesmo nos atributos associados às maiores correlações, observa-se ampla sobreposição entre as classes. Portanto, a presença de dependência linear entre preditores não implica separabilidade das classes de qualidade no espaço bidimensional.

A análise de valores atípicos pelo critério de $1,5 \times IQR$ indicou maior incidência de candidatos a *outliers* em *citric acid* (7,83%), *volatile acidity* (5,80%), *fixed acidity* (5,49%) e *chlorides* (4,40%). Esses pontos também aparecem nas regiões periféricas das distribuições e podem influenciar medidas como o coeficiente de Pearson. Ressalta-se, entretanto, que a identificação pelo critério de IQR caracteriza observações atípicas, e não necessariamente erros de medição.

C. Análise de Componentes Principais

Os dois maiores autovalores obtidos foram aproximadamente $\lambda_1 = 3,030$ e $\lambda_2 = 2,494$. A primeira componente explica 27,54% da variância e a segunda, 22,67%. Considerando os valores não arredondados, a variância explicada acumulada pelas duas componentes é aproximadamente 50,22%.




Figura 4. Dispersão dos atributos envolvidos entre as maiores correlações, com indicação das classes de qualidade.

Tabela V
VARIÂNCIA EXPLICADA PELAS PRIMEIRAS COMPONENTES PRINCIPAIS.

PC	λ	Var. (%)	Acum. (%)
PC1	3,0299	27,54	27,54
PC2	2,4938	22,67	50,22
PC3	1,5563	14,15	64,36
PC4	0,9706	8,82	73,19

A Tabela VI resume os carregamentos de maior magnitude nas duas primeiras componentes.


Tabela VI
CARREGAMENTOS DOMINANTES DAS DUAS PRIMEIRAS COMPONENTES PRINCIPAIS.

Preditor	PC1	PC2
Total sulfur dioxide	0,487	—
Free sulfur dioxide	0,431	—
Volatile acidity	—0,381	—
Residual sugar	0,346	0,330
Density	—	0,584
Alcohol	—	—0,465
Fixed acidity	—	0,336
Chlorides	—	0,315


Na PC1, os maiores carregamentos em magnitude estão associados principalmente a *total sulfur dioxide*, *free sulfur dioxide*, *volatile acidity* e *residual sugar*. Na PC2, destacam-se *density*, *alcohol*, *fixed acidity*, *residual sugar* e *chlorides*.

A interpretação deve considerar principalmente a magnitude relativa dos carregamentos, pois o sinal global de cada autovetor pode ser invertido sem alterar a solução do PCA.

A Fig. 5(a) evidencia forte sobreposição entre as sete



(a) Coloração por qualidade



(b) Coloração por tipo de vinho

Figura 5. Projecção das observações nas duas primeiras componentes principais.

classes de qualidade. Os centroides apresentam deslocamento principalmente ao longo de PC2; para as classes 5, 6, 7 e 8, as médias nessa componente são aproximadamente 0,640, -0,091, -0,840 e -1,152, respectivamente.

Como os desvios padrão intraclasse nessa direção são elevados, a projecção nas duas primeiras componentes não fornece uma representação em que as classes sejam claramente separáveis por fronteiras lineares.

Visualmente, a sobreposição é particularmente intensa entre as classes 5, 6 e 7, que também concentram a maior parte das observações. As classes 7 e 8 também compartilham uma região considerável do espaço projetado. Já a classe 9 possui apenas cinco amostras, o que impede conclusões robustas sobre sua separabilidade.

A Fig. 5(b) apresenta estrutura mais evidente relacionada ao tipo de vinho. Os centroides são aproximadamente (0,821, -0,253) para vinhos brancos e (-2,514, 0,776) para vinhos tintos. Isso sugere que parcela importante da variabilidade capturada pelas primeiras componentes está associada às diferenças físico-químicas entre os dois tipos de vinho.

A Fig. 6 apresenta a contribuição individual das componentes principais para a variância total.

Como as duas primeiras componentes explicam apenas cerca de metade da variância total, parte relevante da informação permanece distribuída pelas componentes seguintes. Assim, a ausência de separação completa no plano PC1-PC2 não implica ausência de informação discriminativa em dimensões superiores.

Além disso, como a PCA é não supervisionada, ela maximiza a variância projetada e não diretamente a separação entre classes. Dessa forma, uma estrutura discriminativa pode existir em direções que não correspondam às componentes de maior variância.

IV. CONCLUSÃO

A análise exploratória do conjunto *Wine Quality* evidenciou forte desbalanceamento entre as classes, assimetrias relevan-




Figura 6. Percentual de variância explicado pelas componentes principais.

tes em vários atributos e dependências lineares entre alguns preditores.

Na análise monovariada, *alcohol* e *volatile acidity* apresentaram tendências associadas à qualidade, porém com elevada sobreposição entre classes vizinhas.

A análise bivariada identificou correlações expressivas, com destaque para *free sulfur dioxide*-*total sulfur dioxide* e *density*-*alcohol*. Os pares de maior correlação apresentam tendências aproximadamente lineares, embora com dispersão e presença de observações atípicas. As diferenças entre correlações obtidas nos subconjuntos tinto e branco indicam ainda heterogeneidade da base agregada.

A PCA implementada a partir da padronização, matriz de covariância e autodecomposição concentrou aproximadamente 50,22% da variância nas duas primeiras componentes. Apesar de deslocamentos entre os centroides das classes, a projecção apresentou ampla sobreposição, principalmente entre as classes centrais de qualidade.

Em conjunto, os resultados indicam que a relação entre

propriedades físico-químicas e qualidade é multivariada e não é adequadamente resumida por um único atributo, por um único par de atributos ou apenas pelas duas primeiras direções principais.

REPOSITÓRIO E USO DE IA

Os códigos, dados e resultados utilizados neste trabalho estão disponíveis no repositório:

https://github.com/Teixeira-art/Homework_ICA.

O repositório contém também as tabelas condicionais completas, os gráficos de dispersão correspondentes aos 55 pares de preditores e os demais resultados gerados durante a análise.

Ferramentas de inteligência artificial generativa foram utilizadas como apoio à organização do relatório, revisão textual e depuração de código. Os prompts e respostas relevantes utilizados durante o desenvolvimento foram disponibilizados no repositório do projeto como material suplementar.

REFERÊNCIAS

- [1] P. Cortez, A. Cerdeira, F. Almeida, T. Matos, and J. Reis, "Modeling wine preferences by data mining from physicochemical properties," *Decision Support Systems*, vol. 47, no. 4, pp. 547–553, 2009.
- [2] I. T. Jolliffe and J. Cadima, "Principal component analysis: a review and recent developments," *Philosophical Transactions of the Royal Society A*, vol. 374, no. 2065, 2016.